

TONALIDADE, VALÊNCIA E POPULARIDADE: UMA ANÁLISE DE RELAÇÃO MUSICAL E STREAMS NO SPOTIFY

João Victor Ribeiro Arruda Figueiro

jvfigueiro@ufrj.br

RESUMO

Este trabalho teve como objetivo a investigação e a análise da relação entre o modo musical, a valência e o número de reproduções (streams) das músicas mais ouvidas do Spotify no ano de 2023, a fim de saber se a hipótese de que músicas Major tendem a uma tonalidade mais alegre (valência superior) e que as Minor, uma mais melancólica (valência inferior) aplica-se ao banco de dados utilizado e se, de tal maneira, essa tonalidade musical influencia o sucesso dessas músicas. Utilizou-se a base de dados disponibilizada no GitHub e a linguagem de programação R para a análise efetiva desses dados. Foi utilizada mediana de tais variáveis e construído gráficos como ferramentas para essa análise. Através dos resultados, observou-se que a mediana foi levemente maior para músicas em Major em relação ao número de streams e uma mediana de valência superior para músicas em modo Minor. Por último, não foi observada uma relação clara entre a valência e o número de reproduções dessas músicas.

1. INTRODUÇÃO

Na sociedade atual, a música tornou-se uma parte intrínseca do dia a dia, a ponto de ser difícil imaginar a vida sem ela. Com isso, a música muitas vezes reflete e influencia o humor das pessoas. Entretanto, diversos elementos que compõem a sonoridade característica de uma canção passam despercebidos pela maioria dos ouvintes. Nesse contexto, este trabalho busca investigar a relação entre o modo musical, a valência e o número de reproduções das músicas mais ouvidas do Spotify em 2023, com o objetivo de verificar se essas características apresentam alguma associação com a popularidade das canções.

2. METODOLOGIA

Foi utilizada, nessa análise, a base de dados das músicas mais reproduzidas no Spotify no ano de 2023 disponibilizada no GitHub. A análise foi feita na linguagem de programação R.

Inicialmente, para a análise de nosso banco de dados, foram usados comandos para conhecer a estrutura dos dados e testar sua qualidade. A visualização geral das primeiras linhas da base foi essencial para a observação das variáveis e suas respectivas estruturas. De igual modo, examinar os nomes das variáveis tornou mais eficiente e organizada a análise. Após isso, foi realizado um resumo estatístico das variáveis e comandos para verificar a existência de dados faltantes, fator fundamental para uma análise completa e de qualidade.

Posteriormente, foram calculadas as frequências da variável **mode**, a qual representa os Modos Musicais (Major e Minor), de modo a observar a distribuição em relação às músicas mais reproduzidas. Após isso, foi calculada a mediana da variável **streams** por modo, comparando o número típico de reproduções entre músicas Major e Minor. De igual modo, foi realizado o cálculo da mediana de **valence** por modo, verificando se há diferença típica entre músicas Major e Minor. Foi utilizado, também, o boxplot de **streams x mode** e de **valence x mode**, permitindo a visualização gráfica da distribuição das streams em cada modo musical e da distribuição da valência para músicas Major e Minor, respectivamente. Por último, foi realizado o scatter plot de **valence x streams** a fim de investigar a relação entre a valência da música e o número de reproduções.

3. RESULTADOS


3.1 Exploração Inicial da Base

Observou-se que a base de dados possui 952 observações e 24 variáveis. A base contém informações tais como: *Número de streams; Modo Musical; Valência; Energia; BPM; Data de lançamento, entre outras.*

Através do resumo estatístico, observou-se que **streams** apresentou grande variação entre as músicas e a presença de um número elevado de outliers, deste modo, optou-se pela utilização da mediana nas comparações, por ser imune a esse fator.

3.2 Dados Faltantes


Foi realizada a verificação dos valores ausentes e nenhuma variável apresentou dados faltantes, indicando que a base estava completa para análises. Esse passo é importante pois a ausência de dados faltantes aumenta a confiabilidade da análise, pois não foi necessário remover observações nem imputar valores. Assim, os resultados podem ser analisados diretamente, pois, como já dito, não foi necessária aplicação de nenhuma técnica de tratamento de dados.




3.3 Comparação Entre Músicas Major e Minor

Inicialmente, foi analisada a distribuição da variável `mode`. Observou-se que a maior parte das músicas da base pertence ao modo **Major**, enquanto uma menor parcela, ao **Minor**. Em seguida, foram comparadas as medianas da variável `streams` para cada modo musical, verificando-se que as músicas em modo **Major** têm uma mediana de streams ligeiramente maior do que a das músicas em modo **Minor**. Posteriormente, analisou-se a variável `valence` em função do modo musical. As músicas classificadas como **Minor** apresentaram mediana de

valência superior à das músicas **Major**.




A **Figura 1** apresenta o boxplot da variável [streams](#) por modo musical. Observa-se a presença de muitos **outliers**, o que significa que algumas músicas concentram um número de valores extremos de reproduções muito superior ao restante da base. Apesar disso, as distribuições dos dois grupos têm comportamento semelhante, não sendo observada uma diferença visual muito acentuada entre as duas.



A **Figura 2** apresenta o boxplot da variável [valence x mode](#), em que uma tendência similar com relação à mediana pode ser observada.

3.4 Relação entre valência e número de reproduções

A relação entre valência e o número de reproduções foi analisada por meio de um scatter plot com linha de regressão. Observou-se que os pontos encontram-se bastante dispersos, não evidenciando uma tendência clara entre as variáveis. Isso sugere que a valência, de maneira isolada, não representa uma relação significativa com o número de reproduções das músicas analisadas.



4. CONCLUSÃO

Com a análise exploratória realizada a partir desses dados, observou-se que as músicas em modo **Major** apresentaram mediana de streams ligeiramente superior às músicas em modo **Minor**. Em relação à valência, as músicas em modo **Minor** apresentaram mediana maior quando comparadas às músicas em modo **Major**. Por fim, a análise entre valência e número de reproduções não apresentou uma tendência clara, indicando que essa característica, isoladamente, não possui uma relação significativa com a popularidade das músicas analisadas. Dessa forma, conclui-se que outros fatores podem exercer maior influência sobre o número de reproduções das músicas no Spotify.

5. REFERÊNCIAS

ELGIRIYEWITHANA, Nidula.

Most Streamed Spotify Songs 2023. GitHub. Disponível em:

<<https://www.kaggle.com/datasets/nelgiriyeewithana/top-spotify-songs-2023/>>. Acesso em: 27 jun. 2026.

CARVALHO, Hugo.

As músicas mais reproduzidas no Spotify em 2023. GitHub. Disponível em:

<github.com/HugoCarvalhoUFRJ/aed/blob/main/materiais-didaticos/spotify-2023-mod.csv>. Acesso em: 27 jun. 2026.

R CORE TEAM. *R: A language and environment for statistical computing*. Vienna: R Foundation for Statistical Computing, 2024. Disponível em: <https://www.r-project.org/>. Acesso em: 27 jun. 2026.

WICKHAM, Hadley et al. *tidyverse: Easily install and Load the 'Tidyverse'*. R package version 2.0.0, 2023. Disponível em: <https://www.tidyverse.org/>. Acesso em: 27 jun. 2026.

IM, Di Cook; LALLY, ... *visdat: Visualising Whole Data Frames*. R package version 0.6.0, 2023. Disponível em: <https://cran.r-project.org/package=visdat>. Acesso em: 27 jun. 2026

SCHLOERKE, Barret et al. *GGally: Extension to ggplot2*. R package version 2.2.1, 2023. Disponível em: <https://cran.r-project.org/package=GGally>. Acesso em: 27 jun. 2026.

APÊNDICE - CÓDIGOS EM R UTILIZADOS

```
install.packages("tidyverse")
install.packages("visdat")
install.packages("GGally")

library("tidyverse")
library("visdat")
library("GGally")

dados <-
read.csv("https://github.com/HugoCarvalhoUFRJ/aed/raw/refs/heads/main/materiais-didaticos/spotify-2023-mo
d.csv", header = TRUE, sep = ',', dec = '.')

head(dados)
names(dados)
# Aqui, utilizou-se o head para visualizarmos as variáveis e suas respectivas estruturas.

summary(dados)
# Aqui foi feito um resumo dos dados contidos

vis_dat(dados)
# Usa-se o vis_dat para verificar se há valores faltantes.

colSums(is.na(dados))

dim(dados)

table(dados$mode)
# A variável "mode" representa o modo musical (Maior e menor).

summary(dados$streams)
# Resumo dos dados

dados %>%
  group_by(mode) %>%
  summarise(
    mediana_streams = median(streams, na.rm = TRUE)
  )
# Aqui, foi observada a mediana de streams por modo musical.
# Observou-se que as músicas em modo maior tiveram a mediana superior às de modo menor.

dados %>%
  group_by(mode) %>%
  summarise(
    mediana_valencia = median(valence_, na.rm = TRUE)
  )
# Com isso, observou-se que as músicas em modo menor apresentaram valência superior.

ggplot(dados, aes(x = mode, y = log10(streams))) +
  geom_boxplot() +
  labs(
```



```

    title = "Distribuição dos Streams por Modo Musical",
    x = "Modo Musical",
    y = "Streams (Log 10)"
  )
  # Major apresentou mediana ligeiramente maior

ggplot(dados, aes(x = mode, y = valence_)) +
  geom_boxplot() +
  labs(
    title = "Distribuição da Valência por Modo Musical",
    x = "Modo Musical",
    y = "Valência"
  )
  # Minor possui maior mediana

ggplot(dados, aes(x = valence_, y = log10(streams))) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  coord_cartesian(ylim = c(7.5, 10)) +
  labs(
    title = "Relação entre Valência e Streams",
    x = "Valência",
    y = "Streams (Log 10)"
  ) +
  theme_bw()

# Sem tend. clara

```